vincent hv

Talk is cheap, show the code!

博客园 闪存 首页 新随笔 联系 管理 订阅

随笔-86 文章-0 评论-3

【译】Spark官方文档——Spark Configuration (Spark配置)

注重版权, 尊重他人劳动

转帖注明原文地址: http://www.cnblogs.com/vincent-hv/p/3316502.html

Spark主要提供三种位置配置系统:

- 环境变量:用来启动Spark workers,可以设置在你的驱动程序或者conf/spark-env.sh 脚本中;
- java系统性能:可以控制内部的配置参数,两种设置方法:
 - 编程的方式(程序中在创建SparkContext之前,使用System.setProperty("xx","xxx")语句 设置相应系统属性值);
 - 在conf/spark-env.sh中配置环境变量SPARK_JAVA_OPTS。
- 日志配置:通过log4j.properties实习

一、环境变量

spark安装目录下的conf/spark-env.sh脚本决定了如何初始化worker nodes的JVM,甚至决定了你在本地如何运 行spark-shell。在Git库中这个脚本默认是不存在的,但是你可以自己创建它并通过复制con/spark-env.sh.temp late中的内容来配置,最后要确保你创建的文件可执行。

在spark-env.sh中你至少有两个变量要设置:

- SCALA_HOME, 指向你的scala安装路径;或者是SCALA_LIBRARY_PATH指向scala library JARS所在 的目录(如果你是通过DEB或者RPM安装的scala,他们是没有SCALA_HOME的,但是他们的libraries是 分离的,默认在/usr/share/java中查找scala-library.jar)
- MESOS_NATIVE_LIBRARY, 如果你要在Mesos上运行集群的话

另外,还有其他四个变量来控制执行。应该将他们设置在启动驱动程序的环境中来取代设置在spark-env.sh,因为 这样这些设置可以自动传递给workers。将他们设置在每个作业中而不是spark-env.sh中,这样确保了每个作业有 他们自己的配置。

- SPARK_JAVA_ORTS,添加JVM选项。你可以通过-D来获取任何系统属性;
- SPARK_CLASS_PATH,添加元素到Spark的classpth中;
- SPARK_LIBARAT_OATH,添加本地libraries的查找目录;
- SPARK_MEM,设置每个节点所能使用的内存总量。他们应该和JVM's -Xmx选项的格式保持一致(e.g.3 00m或1g)。注意:这个选项将很快被弃用支持系统属性spark.executor.memory,所以我们推荐将它 使用在新代码中。

注意:如果你将他们设置在spark-env.sh中,他们将覆盖用户程序设定的值,这是不可取的。如果你喜欢,你可以 选择在spark-env.sh设置他们仅当用户程序没有做任何设置时,例如:

if [-z "\$SPARK_JAVA_OPTS"]; then

SPARK_JAVA_OPTS="-verbose:gc"

fi

二、系统属性

通过设置系统属性来配置Spark,你必须通过以下两种方式中的任意一个来达到目的:

- 在JVM中通过-D标志 (例如: java -Dspark.cores.max=5 MyProgram)
- 在你的程序中创建SparkContext之前调用System.setProperty,如下:

System.setProperty("spark.cores.max", "5")

val sc = new SparkContext(...)

更多可配置的控制内部设置的系统属性已经有了合理的默认属性值。然而,有五个属性通常是你想要去控制的:

属性名称 默认值 含义

昵称: vincent hv 园龄:10个月 粉丝:7 关注:1 +加关注

<	2013年10月					
日	-	=	Ξ	四	五	六
29	30	<u>1</u>	<u>2</u>	3	4	5
6	7	<u>8</u>	9	10	11	12
13	14	15	16	17	18	19
20	<u>21</u>	22	23	24	25	26
27	28	29	30	31	1	2
3	4	5	6	7	8	9

搜索

找找看 谷歌搜索

常用链接

我的随笔 我的评论 我的参与 最新评论 我的标签 更多链接

最新随笔

- 1. linux解压zip乱码解决方案
- 2. 全能系统监控工具dstat
- 3. 【转】linux sar命令详解
- 4. 【原】gnome3增加自定义程序快捷方 #
- 5. 【原】Ubuntu13.04安装、卸载Gnom e3.8
- 6. 【原】安装、卸载、查看软件时常用的 命令
- 7. 【原】中文Ubuntu主目录下的文档文件 夹改回英文
- 8. 【原】Ubuntu ATI/Intel双显卡 驱动安 装
- 9. 【原】Ubuntu 12.04 ATI显卡设置双 屏显示
- 10. 【转】Hadoop vs Spark性能对比

随笔分类

Android(8) Hadoop(2) Java(20) JVM(3) Linux(23) others(1)

Scala(5) Spark(20)

数据结构与算法(2)

第1页 共3页 2013/10/26 星期六 23:03

属性名	默认值	含义		
spark.mes os.coarse	false	如果设置为了"true",将以 <u>粗粒度共享模式</u> 运行在Mesos集群上, 这时候Spark会在每台机器上面获得一个长期运行的Mesos任务,而不是对每个Spark任务都要产生一个Mesos任务。对于很多短查询,这个可能会有些许的延迟,但是会大大提高Spark工作时的资源利用率。		
spark.defa ult.parallel ism	8	在用户没有指定时,用于分布式随机操作(groupByKey,reduceByKey等等)的默认的任务数。		
spark.stor age.mem oryFractio n	0.66	Spark用于缓存的内存大小所占用的Java堆的比率。这个不应该大于JVM中老年代所分配的内存大小,默认情况下老年代大小是堆大小的2/3,但是你可以通过配置你的老年代的大小,然后再去增加这个比率。		
spark.ui.p ort	(random)	你的应用程序控制面板端口号,控制面板中可以显示每个RDD的内存使用情况。		
spark.shuf fle.compr ess	true	是否压缩映射输出文件,通常设置为true是个不错的选择。		
spark.bro adcast.co mpress	true	广播变量在发送之前是否先要被压缩,通常设置为true是个不错的选择。		
spark.rdd. compress	false	是否要压缩序列化的RDD分区(比如,StorageLevel.MEMORY_ONLY_SER)。 在消耗一点额外的CPU时间的代价下,可以极大的提高减少空间的使用。		
spark.red ucer.max MbInFlight	48	同时获取每一个分解任务的时候,映射输出文件的最大的尺寸(以兆为单位)。由于对每个输出都需要我们去创建一个缓冲区去接受它,这个属性值代表了对每个分解任务所使用的内存的一个上限值,因此除非你机器内存很大,最好还是配置一下这个值。		
spark.clos ure.seriali zer	spark.JavaS erializer	用于闭包的序列化类。通常Java是可以胜任的,除非在你的驱动程序中分布式函数(比如map函数)引用了大量的对象。		
spark.kry oserializer .buffer.mb	32	Kryo中运行的对象的最大尺寸(Kryo库需要创建一个不小于最大的单个序列化对象的缓存区)。如果在Kryo中出现"buffer limit exceeded"异常,你就需要去增加这个值了。注意,对每个worker而言,一个核心就会有一个缓冲。		
spark.bro adcast.fac tory	spark.broad cast.HttpBro adcastFactor y	使用哪一个广播实现		
spark.loca lity.wait	3000	在发布一个本地数据任务时候,放弃并发布到一个非本地数据的地方前,需要等待时间。如果你的很多任务都是长时间运行的任务,并且看到了很多的脏数据的话,付就该增加这个值了。但是一般情况下缺省值就可以很好的工作了。		
spark.wor ker.timeou t	60	如果超过这个时间,独立部署master还没有收到worker的心跳回复,那么就认为这个worker已经丢失了。		
spark.akk a.frameSi ze	10	在控制面板通信(序列化任务和任务结果)的时候消息尺寸的最大值,单位是MB。如果你需要给驱动器发回大尺寸的结果(比如使用在一个大的数据集上面使用collet()方法),那么你就该增加这个值了。		
spark.akk a.threads	4	用于通信的actor线程数量。如果驱动器有很多CPU核心,那么在大集群上可以增大这个值。		
spark.akk a.timeout	20	Spark节点之间通信的超时时间,以秒为单位		
spark.driv er.host	(local hostn ame)	驱动器监听主机名或者IP地址.		
spark.driv er.port	(random)	驱动器监听端口号		
spark.clea ner.ttl	(disable)	Spark记忆任何元数据(stages生成,任务生成等等)的时间(秒)。周期性清除保证在这个时间之前的元数据会被遗忘。当长时间几小时,几天的运行Spark的时候设置这个是很有用的。注意:任何内存中的RDD只要过了这个时间就会被清除掉。		
spark.stre aming.blo ckInterval	200	从网络中批量接受对象时的持续时间。		
spark.task .maxFailur es	4	task失败重试次数		

积分与排名

积分 - 5935 排名 - 17402

最新评论᠁

1. Re:全能系统监控工具dstat 感觉好高级的样子,我也下载来玩完

--花瓣奶牛

2. Re:【原】Ubuntu13.04安装、卸载Gn ome3.8

马上应该有13.10了。

--杨琼

3. Re:scala实现kmeans算法

在oschina上一位大牛给我的指点,原文贴上,供跟多的孩纸学习:oldpig 发表于2013-09-0310:451. Source.getLinesr返回的Iterator已经够用了,不需要toArray2.随机初始化k个质心,可以考虑使用Array.fill3.如果你要测算法的计算时间,应将两条println语句放到startTime之前4.计算movement可以考虑使用...

--vincent_hv

阅读排行榜

- 1. Ubuntu 13.04 完全配置(3093)
- 2. Android控件TextView的实现原理分析(213)
- 3. 【转】JVM (Java虚拟机) 优化大全和 案例实战(174)
- 4. 【转】Spark: 一个高效的分布式计算 系统(138)
- 5. 修改Ubuntu12.04 开机启动菜单,包括系统启动等待时间,系统启动顺序(132)

评论排行榜

- 1. 【原】Ubuntu13.04安装、卸载Gnom e3.8(1)
- 2. scala实现kmeans算法(1)
- 3. 全能系统监控工具dstat(1)
- 4. 【转】linux sar命令详解(0)
- 5. 【原】gnome3增加自定义程序快捷方式(0)

推荐排行榜

- 1. 【转】Spark源码分析之-Storage模块(2)
- 2. 【转】弹性分布式数据集:一种基于内存的集群计算的容错性抽象方法(1)
- 3. 【转】Spark:一个高效的分布式计算系统(1)
- 4. linux解压zip乱码解决方案(1)
- 5. 全能系统监控工具dstat(1)

第2页 共3页 2013/10/26 星期六 23:03

三、配置日志

Spark使用log4j来记录。你可以在conf目录中添加log4j.properties文件来配置。一种方法是复制本地已存在的log4j.properties.template

分类: Spark



《 上一篇: 【转】Spark 体系结构》 下一篇: 【转】Spark性能测试报告

posted @ 2013-09-12 11:20 vincent_hv 阅读(122) 评论(0) 编辑 收藏

刷新评论 刷新页面 返回顶部

注册用户登录后才能发表评论,请 登录 或 注册, 访问网站首页。

博客园首页 博问 新闻 闪存 程序员招聘 知识库

最新IT新闻:

- · Google绝密项目:海上数据中心?
- ·WP8版《愤怒的小鸟》和《割绳子》系列全限免
- ・10个疯狂安卓设备:烤箱、冰箱、一个按钮
- 三星智能手表退货率达30%
- · Java程序员应该知道的10个面向对象理论
- » 更多新闻...

最新知识库文章:

- · 软件开发启示录——迟到的领悟
- · 《黑客帝国》里的锡安是不是虚拟世界
- ·深入理解Linux中内存管理
- 工程师文化引出的组织行为话题
- ·如何用美剧真正提升你的英语水平
- » 更多知识库文章...

Copyright ©2013 vincent_hv

第3页 共3页 2013/10/26 星期六 23:03